


Graph-Clustered Block-QAOA for Deepfake Feature Selection

딥페이크 이미지의 Feature Selection을 위한 그래프 기반 클러스터링 블록-QAOA

김은솜(2271018)

김정민(2271020)

이솔민(2271046)





Contents List

01

연구 배경 및 목표

02

기존 연구의 한계 및 연구 제안

03

전체 파이프라인 및 SW 구조

04

주요 기능 및 구현 내용

05


실험 결과

06

Demo

01

연구 배경 및 목표



DEEPFAKE

딥페이크 탐지의 3대 핵심 난제

1. 데이터 중복

중복되거나 판별력 없는 데이터 때문에 불필요한 연산 비용 소모

2. 과적합

과적합으로 인해 새로운 기법을 탐지하는 일반화 능력의 부족

3. 불투명성 (Black-box)

이미지의 어떤 부분이 최종 분류 결정에 기여하는지 알 수 없음

→ 딥페이크 탐지의 가장 시급한 과제는

방대한 고차원 특징 데이터 속에서 최적 조합을 찾아내는 것 !

조합 최적화 문제의 마스터키: 양자 최적화 (QAOA) 도입

02

기존 연구의 한계 및 연구 제안

02 기존 연구의 한계점

현재의 양자컴퓨터는 노이즈가 많고 큐비트 수가 제한적
최근 연구들에서는 고차원 feature를 축소·분할하는 과정이 필수로 동반됨.

	[1] Quantum-Enhanced Federated Learning via QAOA Feature and Gate Selection with Skew-Symmetric Lipschitz Dynamics (2025)	[2] Quantum-Accelerated Feature Selection for Edge-Enabled Perception in Connected and Autonomous Vehicles (2025)	[3] Quantum annealing for enhanced feature selection in single-cell RNA sequencing data analysis (2025)	[4] A Quantum-Hybrid Framework for Enhanced Deepfake Detection: Integrating QAOA-Based Feature Selection With Quantum-Inspired Attention Mechanisms (2026)
핵심 기법	LightGBM Gain으로 feature 중요도를 계산한 뒤, 상위 feature만 남김	Conditional PCA로 고차원 feature를 저차원 선형 공간으로 축소	ANOVA 및 highly variable feature 기준으로 유의미한 feature를 선별	전체 feature를 순차 분할로 나눔. 각 블록별로 QAOA 수행 블록 단위 결과를 결합해 전 feature selection 수행
탐색 범위	개별 특징(Individual)	선형 결합(Linear)	단일 특징(Statistical)	조합 최적화 (Combinatorial)
한계점	특징 간 시너지 무시	비선형 위조 흔적 소실	조합적 위조 단서 소실	블록 경계에서의 정보 소실

딥페이크 feature가 가진 조합적 맥락을 잃어버림


[1] [Quantum-Enhanced Federated Learning via QAOA Feature and Gate Selection](#)
[2] [Quantum-Accelerated Feature Selection for Edge-Enabled Perception in Connected and Autonomous Vehicles](#)
[3] [Quantum Annealing for Enhanced Feature Selection in Single-Cell RNA Sequencing Data Analysis](#)
[4] [A Quantum-Hybrid Framework for Enhanced Deepfake Detection: Integrating QAOA-Based Feature Selection With Quantum-Inspired Attention Mechanisms](#)

02 기존 연구의 한계점

선행연구 [4] - 심층 분석 및 한계점

A Quantum-Hybrid Framework for Enhanced Deepfake Detection: Integrating QAOA-Based Feature Selection With Quantum-Inspired Attention Mechanisms

*QAOA를 딥페이크 탐지 feature selection에 적용한, 본 연구와 가장 가까운 선행연구



* 핵심 메커니즘

전체 데이터셋을 하드웨어가 수용 가능한 크기로 순차적 분할(Index-order)
→ 제한된 큐비트 환경에서도 전체 feature set을 다룰 수 있음.

* 치명적 한계

Feature를 순차적으로 분할하여, 블록 경계에서 정보 유실
→ 데이터 전체를 아우르는 최적의 특징 조합을 찾는 데 실패.

[1]~[3] : 개별 특징을 독립적으로 평가하여 차원을 축소 → **특징 간의 복잡한 시너지 무시**

[4] : 전체 피처를 순차 분할하여 QAOA 적용 → **의미적 단절**


feature들 사이의 의미와 맥락을 고려해서 분할할 수는 없을까?

단순한 데이터 압축이 아닌, 위조 흔적의 관계를 보존하는 Feature Selection 필요 !

따라서, 본 연구에서는
Feature 사이의 의미와 맥락을 보존하는
‘Graph Clustering’ 도입

feature 간의 관계를 반영한 그래프를 모델링하고,
이를 기반으로 전체 특징 공간을 최적의 sub-set으로 분할한다.

이후 각 그룹에 대해 QAOA를 적용하여 위조 흔적을 보존한 최적 feature 조합을 선택한다.




03


전체 파이프라인 및 SW 구조

03 전체 파이프라인 및 SW 구조

DATA - FaceForensics++



1. 딥페이크 위조 특징 다각도 추출



Spatial Features

Frequency Features


Attention Maps

ViT 네트워크

조작의 단서 수집
512 features

2. M-FIG 그래프 모델링

Graph-Clustered



추출된 위조 Feature 간의
관계 네트워크 구축

PyTorch NumPy

feature들의 연결고리 파악해
그래프 형태로 매핑

3. 블록 단위 QAOA 알고리즘

Block-QAOA



앞서 생성한 그래프 기반으로
feature 블록을 분할
→ 블록마다 QAOA 알고리즘 실행

Qiskit

IBM 양자 시뮬레이터 Qiskit의
QAOA 라이브러리 활용

양자 알고리즘으로
feature 조합 최적화
→ features reduction 50% ↑


4. 최종 판별 성능 평가

평가 Metrics

- 정확도
- AUC - ROC
- 정밀도, 재현율
- F1 - Score
- ECE

5. 사용자 데모용 웹 브라우저

gradio



04

주요 기능 및 구현 내용


04 주요 기능 및 구현 내용

[기능 1] Multi-Feature Interaction Graph 모델링


상호 정보량 기반의 가중치 그래프 모델링으로 유사한 특징을 블록 단위로 응집

그래프 구조 설계


1. 각 feature를 node로 간주하고, feature 간 관계를 기반으로 block-wise graph를 구성
2. 코드에 **FeatureAgglomeration(metric='euclidean')**가 포함되어 있어, 유클리드 거리 기반으로 유사한 feature를 묶는 방식을 지원
3. 각 block 내부에서는 $w_{ij} = | \text{corr}(f_i, f_j) |$ 로 edge weight를 정의하고, 이를 QAOA 목적함수에 반영



512 차원의 feature
상관관계를 그래프로 표현



유클리드 거리 기반으로
유사한 feature끼리 Block 구성



adaptive 방식으로
각 블록에서 feature 추출
(256개 or 128개)

그래프 기반 feature selection에서는
QAOA 반복 횟수가 늘어나도 동일한 피처가 뽑힌다.
→ **얕은 레이어에서도 강건하게 동작**

회로 깊이가 늘어나도, 그래프로 사전 클러스터링 된
블록들이 균일한 피처값을 재현해낼 수 있다.
→ **Selection stability**

512D Feature 추출

→ **Clustered Block 구성**

→ **256D or 128D Feature 선택**

[기능 2] 블록 단위 QAOA Feature Selection

1. 고전 비용 함수 설계 (QUBO)

$z_i \in \{0, 1\}$
전체 N개의 특징 중 최적의 부분집합 K개를 선별하는 이진 최적화 문제 설계

$$C(z) = - \sum_{i=1}^N w_i z_i + \lambda \sum_{i < j} c_{ij} z_i z_j + \mu \left(\sum_{i=1}^N z_i - K \right)^2$$

상호 정보량 기반 보상

중복성 최소화 벌점

제약 조건: K개 선택

2. 양자 인코딩(Quantum Encoding)


- 변수 치환: 수학적 이진 변수를 양자역학적 스핀 상태로 변환 $z_i = \frac{1 - \sigma_i^z}{2}$
- COST HAMILTONIAN (H_C): QUBO 비용 함수를 큐비트의 에너지 모델(ISING MODEL)로 매핑. 이 해밀토니안의 바닥 상태가 곧 최적해를 의미.
- MIXER HAMILTONIAN (H_M): $\sum_i \sigma_i^x$ (PAULI-X)
양자 터널링을 유도하여 지역 최적해에 빠지는 것을 방지.

3. 양자-고전 하이브리드 최적화 (QAOA)

- 초기화 상태: 모든 경우의 수(0, 1)가 50:50으로 존재하는 균일 중첩 상태에서 시작
- 회로 진화 (QUANTUM): P개의 레이어(LAYER) 동안 두 해밀토니안을 번갈아 적용하며 양자 상태 진화.
- 파라미터 갱신 (CLASSICAL): 양자 회로 측정 후, 고전 최적화 알고리즘(COBYLA)이 회로 파라미터를 업데이트하며 에너지 기댓값을 지속적으로 최소화.

2. QAOA 설정

```
sampler = StatevectorSampler() # Qiskit 양자 회로 시뮬레이터
optimizer = COBYLA(maxiter=200) # 양자 회로 최적화 고전 알고리즘
qaoa = QAOA(sampler=sampler, optimizer=optimizer, reps=3)
```



04 주요 기능 및 구현 내용

실험 및 검증 방법

DATA PIPELINE

PREPROCESSING

- 얼굴 영역 추출:** MTCNN을 활용한 정밀 얼굴 검출 및 160x160 해상도 정규화
- 데이터 품질 관리:** Laplacian Variance 필터링을 적용하여 임계치 미만의 흐릿한(Blurry) 데이터를 학습에서 제외
- 표준화 및 증강:** ImageNet 통계 기반 정규화 및 다각도 증강(Flip, Rotation, Jitter, Blur)을 적용하여 다양한 조작 변인에 대한 모델 강건성(Robustness) 극대화

DATASET

FaceForensics++: 4가지 주요 딥페이크 기법 포함 (Face2Face, FaceSwap, DeepFakes, NeuralTextures)

데이터셋 분할 비율

Train 70% | Val 15% | Test 15%

BASELINE SETUP

BASELINE SETUP

- 순차 분할 QAOA (SEQUENTIAL QAOA):** 기존의 단순 순차적 피처 분할 방식
- End-to-End SOTA 모델:** 피처 선택션 과정을 거치지 않은 최신 딥페이크 탐지 모델
- [제안 기법] 그래프 기반 QAOA:** M-Fig 스펙트럴 클러스터링을 적용한 하이브리드 피처 선택션 모델

ABLATION STUDY (구성 요소별 기여도 분석)

- QAOA 회로 깊이 분석:** Circuit Depth 변화가 최적해 탐색 성능 및 컴퓨팅 자원에 미치는 영향 비교
- M-Fig 파라미터 민감도:** 그래프 가중치(중복성, 시너지, 노이즈) 변화에 따른 분류기 성능 변화 분석
- 블록 크기 효율성:** 스펙트럴 클러스터링의 MAX BLOCK SIZE 조절에 따른 메모리 한계(RAM) 극복

EVALUATION

분류 성능 지표

- Accuracy:** 전체 데이터 중 올바르게 예측한 비율
- Precision:** 양성 예측 중 실제 양성인 비율 (오진 최소화)
- Recall:** 실제 양성 데이터 중 제대로 찾아낸 비율
- F1-Score:** Precision과 Recall의 조화평균 (데이터 불균형 보완)
- AUC-ROC:** 임계값 변화에 따른 종합적인 판별 성능 지표

신뢰성 및 범용성 검증



- ECE (Expected Calibration Error):** 모델의 예측 확신도와 실제 정답률의 일치 여부를 평가하여 '포렌식 증거'로서의 법적/실무적 신뢰성 검증
- 일반화 검증:** 특정 기법으로만 학습한 모델을 미지 (Unseen)의 딥페이크 기법에 테스트하여 모델의 과적합 여부 및 범용적 탐지력 평가

05

실험 결과

선행 연구와의 비교

동일 실험 환경에서 연산 효율성 향상 (속도 개선) 확인

	연산 시간	중복 완화
단순 순차 분할 (기존 연구)	전체 32블록 블록 당 331.71초 총 2시간 56분 54초	
M-FIG 그래프 기반 클러스터링 분할	전체 42블록 블록 당 59.14초 총 42분 23초	 그래프 기반으로 유사한 피처를 묶었으므로, 중요도가 높더라도 중복된 피처가 우선 제거되는 양상

성능 검증

전처리한 5만장의 딥페이크 이미지 데이터로 탐지 실험 진행

	ViT (Attn SOTA)	ResNet+CBAM	SRM+CNN (Freq)	순차 QAOA	그래프 클러스터링 QAOA	그래프 클러스터링 small QAOA
Num of Feature	512	512	512	256	256	128 우수한 feature 압축률
Acc	85.80%	89.56%	90.05%	88.93%	89.27%	89.56%
Pre	85.60%	91.45%	91.22%	91.64%	93.46% False Positive 오탐 최소화	92.36%
Rec	99.21%	96.13%	97.09%	95.04%	93.31%	95.00%
F1	91.90%	93.73%	94.07%	93.31%	93.39%	93.66%
AUC	93.77%	92.63%	96.00%	92.86%	94.10%	93.53%

그래프 클러스터링 QAOA는 데이터 간 유사도 관계를 활용하여 노이즈 영향을 감소시키고 안정적인 분류 수행

순차 분할 QAOA 대비 4배 빠른 실행 속도 & 2배 작은 Feature set으로도 정확도 성능 우위 입증
딥러닝 기반 모델 대비, 4배 적은 Feature로도 유사한 성능을 달성

Next step

NeuralTextures 기법을 제외한 데이터셋만을 학습 → unseen manipulation에 대한 일반화 성능 테스트

기술적 목표


데이터셋 보강을 통한 Accuracy 향상

95% 이상



구조적 관계를 보존해
일반화 Accuracy 향상


80% 이상



전체 feature의

50% 이상

압축 하면서도 성능 유지 또는 향상



예상 산출물

FaceForensics++ 데이터셋 대상 딥페이크 탐지 모델 feature selection 프레임워크

사용자 데모용 웹 애플리케이션

Attention/Activation 기반 설명 가능한 시각화 결과



DEMO



Q & A

Graph-Clustered Block-QAOA for Deepfake Feature Selection

딥페이크 이미지의 Feature Selection을 위한 그래프 기반 클러스터링 블록-QAOA